

Predicción de demanda y generación renovable con Deep Learning: Aplicación a la optimización de estaciones de carga de vehículos eléctricos

Francisco Ramos-Pérez, Carlos Vivas Venegas, Francisco R. Rubio

Dpto. Ingeniería Sistemas y Automática, Universidad de Sevilla



INTRODUCCIÓN

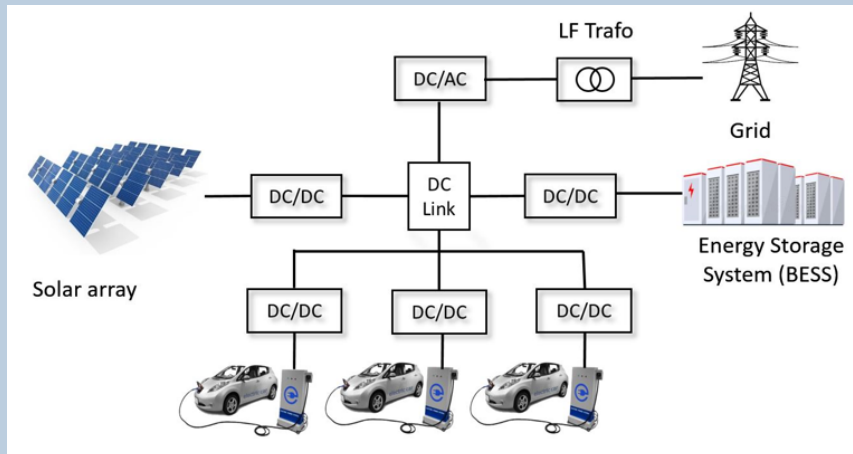
La creciente adopción de vehículos eléctricos como clave para un futuro sostenible plantea desafíos para la infraestructura eléctrica actual. La gestión inteligente de la carga a través de técnicas de aprendizaje automático y datos se presenta como solución. Este artículo presenta un estudio que utiliza modelos de redes neuronales para predecir la demanda de carga y la generación fotovoltaica. Los resultados destacan la eficacia de los modelos en la predicción de la demanda y generación, con redes LSTM liderando en la predicción de demanda y modelos CNN+LSTM en generación.

OBJETIVO

El propósito principal de esta investigación es diseñar y evaluar un sistema de gestión energética para estaciones de carga de VEs, empleando técnicas de optimización y predicción basadas en datos históricos y en tiempo real. El objetivo es maximizar el uso de energía renovable y mejorar la eficiencia operativa de la estación de carga.

SIMULADOR DE ESTACIÓN DE VES

Se presenta una arquitectura del simulador de estación de carga inteligente. El sistema incluye componentes como paneles solares, inversores, baterías de almacenamiento y cargadores de diferentes capacidades. Se explica cómo estos elementos interactúan para proporcionar una carga óptima a los vehículos eléctricos y minimizar la carga de la red convencional.



PROBLEMA DE OPTIMIZACIÓN

La variabilidad en la generación de energía renovable y la fluctuante demanda de carga hacen nece una optimización y planificación dinámica. El problema de optimización se ha formulado teniendo como objetivo la minimización del coste monetario de la planta.

$$\min_u J(t) = \sum_{k=1}^{SH} (J_{GRID}(t_k|t) + J_{BES}(t_k|t)) \quad (1)$$


El término $J_{GRID}(t_k|t)$ es la penalización provocada por utilizar la potencia suministrada por la red eléctrica en el instante t_k , conocidos los datos del instante t . Este término podría reducir el coste total del sistema si la planta vende potencia a la red.

El término $J_{BES}(t_k|t)$ tiene en cuenta la depreciación que sufren las baterías después de cada kWh cargado o descargado y la penalización provocada por el deterioro de las baterías asociado a los ciclos de carga y descarga.

PREDICCIÓN DE DEMANDA

Se aborda una predicción a medio-largo plazo con un horizonte de 24 horas (24 valores) empleando datos reales de sesiones de carga en una estación de la Universidad de Caltech, Estados Unidos (Lee et al., 2019).


Los datos requieren un preprocesamiento para obtener series temporales de demanda horaria que incluyan la potencia media intercambiada en cada intervalo de tiempo. Este proceso implica la lectura y carga de datos, cálculo de la duración de sesiones a partir de su hora de inicio y fin, estimación de la potencia media dividiendo la energía entre el tiempo, y obtención de la suma de las potencias medias de las de sesiones de carga concurrentes en cada franja horaria.



PREDICCIÓN DE GENERACIÓN

Para la predicción de la generación se usan modelos con entradas de datos multidimensionales. Los modelos se entrenarán con secuencias de variables múltiples que incorporan información sobre producciones pasadas y condiciones meteorológicas.

Se presentan diversos modelos de redes neuronales con variadas arquitecturas para predecir a largo plazo en un horizonte temporal de 24 horas. El proceso involucra preprocesar los datos, seleccionar y validar los modelos, así como probarlos y analizar los resultados obtenidos.




MODELOS

En la búsqueda de una arquitectura óptima para los algoritmos de predicción, se exploran diversos modelos con diferentes tipos de redes neuronales. Se presentan enfoques que incluyen redes neuronales simples, recurrentes, LSTM, convolucionales y bidireccionales, así como combinaciones de estas arquitecturas. Se discute cómo cada tipo de modelo puede abordar distintos aspectos del problema.

Los Perceptrones Multicapa (MLP), por ejemplo, son robustos ante el ruido en los datos y pueden manejar características multidimensionales, aunque pierden la dimensión temporal. Las redes neuronales recurrentes (RNN) consideran la temporalidad, lo que es crucial para la predicción de series temporales. Además, se explora el uso de LSTM para capturar relaciones a largo plazo y se presenta un modelo complejo de red neuronal convolucional y LSTM (CNN+LSTM) que podría ser más adecuado para desafíos de predicción más difíciles, en función de la dimensión de las secuencias de entrada.

RESULTADOS



Se representa en las dos figuras de la izquierda las predicciones de la demanda con un horizonte temporal de 24 horas y una comparativa con las predicciones de los distintos modelos. Del mismo modo, en las dos figuras de la izquierda se muestran las predicciones de la generación en un horizonte temporal de 24 y una comparativa.

Para comparar el funcionamiento de los distintos modelos utilizados se han utilizado las métricas del error cuadrático medio (RMSE) y el error absoluto medio (MAE). Se puede observar que para la predicción de la demanda el modelo que mejor se ajusta es el LSTM. Por otro lado, para la predicción de la generación el mejor modelo es el CNN+LSTM, demostrando su mayor capacidad de retener características de datos multidimensionales.

w.size	Métricas	ANN	RNN	st-RNN	LSTM	st-LSTM	Bi-LSTM	CNN + LSTM
96	RMSE train (kW)	4.46	4.20	4.27	4.09	4.03	4.15	4.17
	RMSE test (kW)	4.62	4.30	4.25	4.10	4.07	4.23	4.23
	MAE train (kW)	3.10	2.94	2.99	2.69	2.69	2.83	2.84
	MAE test (kW)	3.21	3.09	2.93	2.66	2.70	2.86	2.88
168	RMSE train (kW)	4.51	4.22	4.21	4.05	4.07	3.93	4.08
	RMSE test (kW)	4.72	4.39	4.35	4.12	4.13	3.96	4.08
	MAE train (kW)	3.40	2.85	2.95	2.72	2.70	2.72	2.76
	MAE test (kW)	3.59	2.86	3.06	2.73	2.68	2.68	2.75

w.size	Métricas	RNN	st-RNN	LSTM	st-LSTM	Bi-LSTM	CNN + LSTM
24	RMSE train (kW)	94.21	92.71	99.78	100.67	94.69	96.28
	RMSE test (kW)	114.98	117.32	108.25	109.89	105.44	104.61
	MAE train (kW)	47.31	52.60	51.44	56.38	49.50	49.00
	MAE test (kW)	60.37	64.45	58.55	62.82	56.06	55.60
96	RMSE train (kW)	94.49	-	103.08	101.40	97.26	96.30
	RMSE test (kW)	119.57	-	107.35	115.08	108.44	110.75
	MAE train (kW)	50.88	-	53.04	57.09	55.40	52.00
	MAE test (kW)	67.46	-	58.01	69.35	61.05	62.35

REFERENCIAS

- [1] Hüttel, F. B., Peled, I., Rodrigues, F., Pereira, F. C. (2021). Deep spatio-temporal forecasting of electrical vehicle charging demand. arXiv preprint arXiv:2106.10940.
- [2] Kim, Y., Kim, S. (2021). Forecasting charging demand of electric vehicles using time-series models. Energies, 14(5), 1487.
- [3] Lee, Z. J., Li, T., Low, S. H. (2019). ACN-Data: Analysis and Applications of an Open EV Charging Dataset. In Proceedings of the Tenth International Conference on Future Energy Systems.
- [4] Llamas, A. L. (2022). Optimización de carga de vehículos eléctricos con asistencia solar fotovoltaica y almacenamiento de energía.
- [5] Shahriar, S., Al-Ali, A.-R., Osman, A. H., Dhou, S., Nijim, M. (2021). Prediction of ev charging behavior using machine learning. IEEE Access, 9, 111576–111586.

